

Васильев В.М., РКН^о1, ИУ5Ц-81Б, вариант N^о28

Задача N^о4. Для заданного набора данных постройте основные графики, входящие в этап разведочного анализа данных. В случае наличия пропусков в данных удалите строки или колонки, содержащие пропуски. Какие графики Вы построили и почему? Какие выводы о наборе данных Вы можете сделать на основании построенных графиков?

Датасет N^о4 Heart Disease Dataset (kaggle.com)

<https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset>

Импорт библиотек и открытие датасета

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import sys
sys.path
%matplotlib inline
```

```
data = pd.read_csv('heart.csv')
data.head()
```

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak
0	52	1	0	125	212	0	1	168	0	1.0
1	53	1	0	140	203	1	0	155	1	3.1
2	70	1	0	145	174	0	1	125	1	2.6
3	61	1	0	148	203	0	1	161	0	0.0
4	62	0	0	138	294	1	1	106	0	1.9

	ca	thal	target
0	2	3	0
1	0	3	0
2	0	3	0
3	1	3	0
4	3	2	0

Приступим к разведочному анализу. Для начала проверим датасет на корректность данных.

```
# первые пять строк датасета
data.head()
```

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak
0	52	1	0	125	212	0	1	168	0	1.0
1	53	1	0	140	203	1	0	155	1	3.1
2	70	1	0	145	174	0	1	125	1	2.6
3	61	1	0	148	203	0	1	161	0	0.0
4	62	0	0	138	294	1	1	106	0	1.9

	ca	thal	target
0	2	3	0
1	0	3	0
2	0	3	0
3	1	3	0
4	3	2	0

```
#информация о датасете
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1025 entries, 0 to 1024
Data columns (total 14 columns):
#   Column      Non-Null Count  Dtype
---  -
0   age         1025 non-null   int64
1   sex         1025 non-null   int64
2   cp          1025 non-null   int64
3   trestbps    1025 non-null   int64
4   chol        1025 non-null   int64
5   fbs         1025 non-null   int64
6   restecg     1025 non-null   int64
7   thalach     1025 non-null   int64
8   exang       1025 non-null   int64
9   oldpeak     1025 non-null   float64
10  slope       1025 non-null   int64
11  ca          1025 non-null   int64
12  thal        1025 non-null   int64
13  target      1025 non-null   int64
dtypes: float64(1), int64(13)
memory usage: 112.2 KB
```

```
#проверим на пропуски еще раз
data.isnull().sum()
```

```
age          0
sex          0
cp           0
trestbps     0
chol         0
fbs          0
restecg      0
thalach       0
exang        0
oldpeak      0
slope        0
ca           0
thal         0
target       0
dtype: int64
```

Описание датасета показало отсутствие пропусков а также тип данных 14 столбцов. Общее количество записей 1024. Описание столбцов

1.age - возраст 2.sex - пол 3.chest pain type (4 values) - тип боли в груди 4.resting blood pressure - артериальное давление в состоянии покоя 5.serum cholestoral in mg/dl - уровень холестерина в сыворотке крови натощак, мг/дл 6.fasting blood sugar > 120 mg/dl - уровень сахара в крови натощак > 120 мг/дл 7.resting electrocardiographic results (values 0,1,2) - результаты электрокардиографии в состоянии покоя (значения 0,1,2) 8.maximum heart rate achieved - достигнута максимальная частота сердечных сокращений 9.exercise induced angina -стенокардия, вызванная физической нагрузкой 10.oldpeak = ST depression induced by exercise relative to rest - олдпик = депрессия ST, вызванная физической нагрузкой по сравнению с отдыхом. 11.the slope of the peak exercise ST segment - наклон сегмента ST пикового упражнения 12.number of major vessels (0-3) colored by flourosopy - количество крупных сосудов (0-3), окрашенных методом флуороскопии 13.thal: 0 = normal; 1 = fixed defect; 2 = reversable defect -флуороскопии: 0 = нормальный; 1 = фиксированный дефект; 2 = обратимый дефект 14. target - цель(0-1), целевая переменная, на наличие или отсутствие сердечный заболеваний

```
data.describe()
```

```
#Статистические данные
```

	age	sex	cp	trestbps	chol
\count	1025.000000	1025.000000	1025.000000	1025.000000	1025.000000
mean	54.434146	0.695610	0.942439	131.611707	246.000000
std	9.072290	0.460373	1.029641	17.516718	51.59251
min	29.000000	0.000000	0.000000	94.000000	126.000000


25%	48.000000	0.000000	0.000000	120.000000	211.000000
50%	56.000000	1.000000	1.000000	130.000000	240.000000
75%	61.000000	1.000000	2.000000	140.000000	275.000000
max	77.000000	1.000000	3.000000	200.000000	564.000000
	fbs	restecg	thalach	exang	oldpeak
\					
count	1025.000000	1025.000000	1025.000000	1025.000000	1025.000000
mean	0.149268	0.529756	149.114146	0.336585	1.071512
std	0.356527	0.527878	23.005724	0.472772	1.175053
min	0.000000	0.000000	71.000000	0.000000	0.000000
25%	0.000000	0.000000	132.000000	0.000000	0.000000
50%	0.000000	1.000000	152.000000	0.000000	0.800000
75%	0.000000	1.000000	166.000000	1.000000	1.800000
max	1.000000	2.000000	202.000000	1.000000	6.200000
	slope	ca	thal	target	
count	1025.000000	1025.000000	1025.000000	1025.000000	
mean	1.385366	0.754146	2.323902	0.513171	
std	0.617755	1.030798	0.620660	0.500070	
min	0.000000	0.000000	0.000000	0.000000	
25%	1.000000	0.000000	2.000000	0.000000	
50%	1.000000	0.000000	2.000000	1.000000	
75%	2.000000	1.000000	3.000000	1.000000	
max	2.000000	4.000000	3.000000	1.000000	

Разведочный анализ

Проанализируем целевую переменную

```
target_count = data['target'].value_counts()
plt.figure()
target_counts.plot(kind='bar')
plt.title('Распределение целевой переменной')
plt.xlabel('Наличие сердечного заболевания (0 = Нет, 1 = Да)')
plt.ylabel('Количество')
```

```
plt.xticks(rotation=0)
plt.show()
```



Отсюда вывод что количество заболевших ненамного больше, чем здоровых.

Создадим диаграмму распределения заболеваний по полу.


```
sex_counts = data['sex'].value_counts()


sex_counts.plot(kind='bar', color=['blue', 'pink'])

plt.title('Распределение по полу')
plt.xlabel('Пол')
plt.ylabel('Количество')
plt.xticks(ticks=[0, 1], labels=['Мужской', 'Женский'], rotation=0)

plt.show()
pd.crosstab(data.target, data.sex).plot(kind="bar")
plt.title('Распределение заболеваний по полу')
plt.xlabel('Наличие сердечного заболевания')
plt.ylabel('Количество пациентов')
plt.xticks(ticks=[0, 1], labels=['Нет', 'Да'], rotation=0)
```

```
plt.legend(title='Пол', labels=['Женский', 'Мужской'])  
plt.show()
```





Можно сделать вывод, что в исследовании мужчин принимает участие в более чем два раза больше чем женщин. Также больных женщин больше в 2.5 раза чем здоровых, а здоровых мужчин наоборот больше чем больных

Создадим диаграмму распределения людей по возрасту

```
data['age'].plot(kind='hist', bins=40)


plt.title('Распределение по возрасту')
plt.xlabel('Возраст')
plt.ylabel('Количество')
plt.xticks(range(30, 80, 5))
plt.show()
```



Создадим диаграмму зависимости заболеваний от возраста

```
# Группировка данных по возрасту и подсчет количества заболеваний в
каждой возрастной группе
age_target_counts = data.groupby('age')['target'].sum()

# Построение графика зависимости количества заболеваний от возраста
plt.figure(figsize=(12, 6))
plt.plot(age_target_counts.index, age_target_counts.values,
marker='o', linestyle='-')
plt.title('Зависимость количества заболеваний от возраста')
plt.xlabel('Возраст')
plt.ylabel('Количество заболеваний')
plt.xticks(rotation=0)
plt.grid(True) # Включение сетки для лучшей визуализации
plt.show()
```

По данной диаграмме зависимость не прослеживается, только то, что в диапазоне 50-60 лет больше всего заболеваний, но и количество людей, участвующих в исследовании в данном диапазоне, больше чем в других.


Диаграмма зависимости уровня холестерина от возраста.

```
plt.scatter(data.age[data.target == 1],
            data.chol[data.target == 1])

plt.scatter(data.age[data.target == 0],
            data.chol[data.target == 0],)

plt.xlabel("Возраст")
plt.ylabel("Холестерин")
plt.legend(["Болезнь", "Нет болезни"])
plt.title("Заболевания сердца в зависимости от возраста и уровня
холестерина")
plt.xticks(rotation = 0)
plt.show()
```

Заболевания сердца в зависимости от возраста и уровня холестерина



По данной статистике можно отметить, что у больных людей уровень холестерина в среднем ниже чем у здоровых людей, а также есть аномальное значение с предельно высоким значением холестерина.


```
plt.scatter(data.age[data.target == 1], data.thalach[data.target == 1])
plt.scatter(data.age[data.target == 0], data.thalach[data.target == 0])
plt.xlabel("Возраст")
plt.ylabel("Максимальный пульс")
plt.legend(["Болезнь", "Нет болезни"])
plt.title("Сердечное заболевание по возрасту и максимальному пульсу")
plt.xticks(rotation=0)
plt.show()
```



Отсюда можно сделать вывод, что у людей с сердечными болезнями средний пульс выше среднего пульса здоровых людей.

```
pd.crosstab(data.cp, data.target).plot(kind="bar", figsize=(10, 6))

plt.title("Сердечное заболевание в зависимости от боли в груди")
plt.xlabel("Тип боли в груди")
plt.ylabel("Сердечное заболевание")
plt.legend(["Заболевание", "Нет заболевания"])
plt.xticks(rotation=0)
plt.show()
```



Можно наблюдать, что у больных людей в большинстве нулевой тип боли, а у здоровых людей преобладает второй тип боли.

Матрица корреляции

```
cor_matrix = data.corr() cor_matrix
```

```
cor_matrix = data.corr()
cor_matrix
```

	age	sex	cp	trestbps	chol	fbs	restecg
age	1.000000	-0.103240	-0.071966	0.271121	0.219823	0.121243	
sex	-0.103240	1.000000	-0.041119	-0.078974	-0.198258	0.027200	
cp	-0.071966	-0.041119	1.000000	0.038177	-0.081641	0.079294	
trestbps	0.271121	-0.078974	0.038177	1.000000	0.127977	0.181767	
chol	0.219823	-0.198258	-0.081641	0.127977	1.000000	0.026917	
fbs	0.121243	0.027200	0.079294	0.181767	0.026917	1.000000	
restecg	-0.132696	-0.055117	0.043581	-0.123794	-0.147410	-0.104051	1.000000

thalach	-0.390227	-0.049365	0.306839	-0.039264	-0.021772	-0.008866
exang	0.088163	0.139157	-0.401513	0.061197	0.067382	0.049261
oldpeak	0.208137	0.084687	-0.174733	0.187434	0.064880	0.010859
slope	-0.169105	-0.026666	0.131633	-0.120445	-0.014248	-0.061902
ca	0.271551	0.111729	-0.176206	0.104554	0.074259	0.137156
thal	0.072297	0.198424	-0.163341	0.059276	0.100244	-0.042177
target	-0.229324	-0.279501	0.434854	-0.138772	-0.099966	-0.041164


	restecg	thalach	exang	oldpeak	slope	
ca \						
age	-0.132696	-0.390227	0.088163	0.208137	-0.169105	0.271551
sex	-0.055117	-0.049365	0.139157	0.084687	-0.026666	0.111729
cp	0.043581	0.306839	-0.401513	-0.174733	0.131633	-0.176206
trestbps	-0.123794	-0.039264	0.061197	0.187434	-0.120445	0.104554
chol	-0.147410	-0.021772	0.067382	0.064880	-0.014248	0.074259
fbs	-0.104051	-0.008866	0.049261	0.010859	-0.061902	0.137156
restecg	1.000000	0.048411	-0.065606	-0.050114	0.086086	-0.078072
thalach	0.048411	1.000000	-0.380281	-0.349796	0.395308	-0.207888
exang	-0.065606	-0.380281	1.000000	0.310844	-0.267335	0.107849
oldpeak	-0.050114	-0.349796	0.310844	1.000000	-0.575189	0.221816
slope	0.086086	0.395308	-0.267335	-0.575189	1.000000	-0.073440
ca	-0.078072	-0.207888	0.107849	0.221816	-0.073440	1.000000
thal	-0.020504	-0.098068	0.197201	0.202672	-0.094090	0.149014
target	0.134468	0.422895	-0.438029	-0.438441	0.345512	-0.382085

	thal	target
age	0.072297	-0.229324
sex	0.198424	-0.279501
cp	-0.163341	0.434854
trestbps	0.059276	-0.138772

```
chol      0.100244 -0.099966
fbs       -0.042177 -0.041164
restecg   -0.020504  0.134468
thalach   -0.098068  0.422895
exang      0.197201 -0.438029
oldpeak    0.202672 -0.438441
slope     -0.094090  0.345512
ca         0.149014 -0.382085
thal       1.000000 -0.337838
target    -0.337838  1.000000
```

```
cor_matrix = data.corr()
plt.figure(figsize = (15,9))
sns.heatmap(cor_matrix,
            annot = True,
            linewidth = 1,
            fmt= ".3f",
            cmap="YlGnBu"
            )
```

<Axes: >



С помощью матрицы корреляции можно выяснить исходя из значений зависимость переменных друг от друга. Например видна прямая зависимость типа боли в груди и уровня наклона сегмента ST к целевой переменной

Дополнительное задание

```
# Выбираем данные для оси x (возраст) и оси y (уровень холестерина)
x = data['age']
y = data['chol']

# Строим диаграмму рассеяния
plt.figure(figsize=(8, 6))
plt.scatter(x, y, alpha=0.5, color='blue')
plt.title('Диаграмма рассеяния: Возраст vs Уровень холестерина')
plt.xlabel('Возраст')
plt.ylabel('Уровень холестерина')
plt.grid(True)
plt.show()
```

