

РКН^о2 Вариант 27 Линейная/логистическая регрессия Случайный лес

Васильев В.М. ИУ5Ц-81Б

<https://www.kaggle.com/datasets/roysouravcu/forbes-billionaires-of-2021/code>

```
# библиотеки
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, classification_report
import matplotlib.pyplot as plt
import seaborn as sns
# Загрузка данных
data = pd.read_csv('Billionaire.csv')
```

Выведем данные и очистим нулевые значения

```
data.head()
```

	Name	NetWorth	Country	Source
Rank \				
0	Jeff Bezos	\$177 B	United States	Amazon
1				
1	Elon Musk	\$151 B	United States	Tesla, SpaceX
2				
2	Bernard Arnault & family	\$150 B	France	LVMH
3				
3	Bill Gates	\$124 B	United States	Microsoft
4				
4	Mark Zuckerberg	\$97 B	United States	Facebook
5				

	Age	Industry
0	57.0	Technology
1	49.0	Automotive
2	72.0	Fashion & Retail
3	65.0	Technology
4	36.0	Technology

```
data.isnull().sum()
```

Name	0
NetWorth	0

```

Country      0
Source       0
Rank         0
Age         79
Industry     0
dtype: int64

data=data.dropna()
data.isnull().sum()

Name         0
NetWorth     0
Country      0
Source       0
Rank         0
Age         0
Industry     0
dtype: int64

```

Преобразование данных

```

data["NetWorth"] = data["NetWorth"].str.strip("$")
data["NetWorth"] = data["NetWorth"].str.strip(" B")
data["NetWorth"] = data["NetWorth"].astype(float)

data.head()

```

	Rank	Name	NetWorth	Country	Source
0	0	Jeff Bezos	177.0	United States	Amazon
1	1	Elon Musk	151.0	United States	Tesla, SpaceX
2	2	Bernard Arnault & family	150.0	France	LVMH
3	3	Bill Gates	124.0	United States	Microsoft
4	4	Mark Zuckerberg	97.0	United States	Facebook
5					

	Age	Industry
0	57.0	Technology
1	49.0	Automotive
2	72.0	Fashion & Retail
3	65.0	Technology
4	36.0	Technology

Проведем кодирование категориальных признаков и масштабирование данных

```
from sklearn.preprocessing import LabelEncoder, MinMaxScaler
le = LabelEncoder()
le.fit(data['Name'].drop_duplicates())
data['Name'] = le.transform(data['Name'])


le.fit(data['Country'].drop_duplicates())
data['Country'] = le.transform(data['Country'])

le.fit(data['Source'].drop_duplicates())
data['Source'] = le.transform(data['Source'])

le.fit(data['Industry'].drop_duplicates())
data['Industry'] = le.transform(data['Industry'])

# Масштабирование данных
scaler = MinMaxScaler()
scaled_data = scaler.fit_transform(data)

# Построение тепловой карты корреляции
plt.figure(figsize=(10, 5))
sns.heatmap(data.corr(method='pearson'), annot=True, fmt='.3f')
plt.title('Correlation Heatmap')
plt.show()
```



```
data.head()
```

	Name	NetWorth	Country	Source	Rank	Age	Industry
0	1015	177.0	66	6	1	57.0	16
1	598	151.0	66	143	2	49.0	0
2	221	150.0	16	86	3	72.0	4
3	238	124.0	66	96	4	65.0	16
4	1521	97.0	66	48	5	36.0	16

Линейная регрессия целевого признака Rank

```

from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression, LogisticRegression
from sklearn.metrics import mean_squared_error, accuracy_score

# Определение признаков и целевой переменной
X = data.drop(columns=['Rank']) # Все признаки, кроме Rank
y = data['Rank'] # Целевая переменная - Rank

# Разделение данных на обучающий и тестовый наборы
X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.2, random_state=42)

from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error

# Создание и обучение модели линейной регрессии
lr = LinearRegression()
lr.fit(X_train, y_train)

# Предсказание на тестовой выборке
y_pred_lr = lr.predict(X_test)

# Оценка модели
mse = mean_squared_error(y_test, y_pred_lr)
print(f"Модель линейной регрессии: Среднеквадратичная ошибка (MSE) = {mse}")

Модель линейной регрессии: Среднеквадратичная ошибка (MSE) = 426276.07910038956

```

Случайный лес

```

from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score

# Создание и обучение модели случайного леса
rf = RandomForestRegressor(n_estimators=100, random_state=42)
rf.fit(X_train, y_train)

# Предсказание на тестовой выборке

```

```
y_pred_rf = rf.predict(X_test)

# Оценка модели
mae = mean_absolute_error(y_test, y_pred_rf)
mse = mean_squared_error(y_test, y_pred_rf)

print(f"Случайный лес: Средняя абсолютная ошибка (MAE) = {mae},  
Среднеквадратичная ошибка (MSE) = {mse}")

Случайный лес: Средняя абсолютная ошибка (MAE) = 0.16281716417910466,  
Среднеквадратичная ошибка (MSE) = 0.2759953358208952
```

Исходя из этих результатов, можно сделать вывод, что модель случайного леса предпочтительнее для данной задачи предсказания ранга миллиардеров по сравнению с моделью линейной регрессии.